核心代码数学解析 —— 不看代码，只看公式

> 目标：**不读代码**也能明白 `RSM_functions` 到底在算什么。
> 全部结论都写成公式，每条公式都标出"它对应哪一行代码"。
> 配套：`README.md`（怎么用）、`精读指南.md`（怎么读代码）、`outputs/RSM显式公式.txt`（你的系数）

第 0 章 · 一句话总览

整个项目从头到尾就是**一条公式链**：



六个文件里，**只有 `rsm_model.py` 是数学**，其余全是数据搬运和存储。

第 1 章 · 需要补的知识方向

按"缺了会卡在哪"排序，不是按学术重要性排。

第 0 层 · 缺了完全看不懂（必补）

#	方向	为什么你的代码需要它	学到什么程度
1	**多元线性回归的矩阵形式**	`rsm_model.py` 全部 109 行都是它的实现。不懂 X^TX、不懂"正规方程"，`fit_model` 的每一行都是天书	会手推 $\hat{\beta}=(X^TX)^{-1}X^Ty$，能解释 $\mathrm{Var}(\hat{\beta})=\sigma^2(X^TX)^{-1}$
2	**基函数展开 / 特征映射**	为什么 4 个变量能变成 14 个？为什么"非线性拟合"最后变成"线性回归"？	理解"模型线性 ≠ 输入线性"

核心要建立的观念：`PolynomialFeatures` 没干什么高级的事，它只是把原来的 4 维输入**映射**到 14 维空间，然后在新空间里做**普通的线性回归**。所谓"曲面"，就是高维空间里的一个平面。

第 1 层 · 决定数值可不可靠

#	方向	为什么需要
3	**中心化 / 标准化**	你代码里连着做了两次（减均值、除标准差）。不理解它们，就不知道为什么要写这两步、删掉会怎样
4	**岭回归与正则化**	你的求解器是 `Ridge` 不是 `LinearRegression`，这是本项目唯一的"算法选择"

关键概念：条件数、共线性、L2 惩罚、SVD 视角下的**收缩因子**、偏差-方差权衡。
这一条直接解释了你"α 怎么调都没变化"的困惑（见第 4 章结论 ③）。

第 2 层 • 决定结论可不可信

#	方向	为什么需要
5	**模型评价与验证**	R^2、RMSE、MAE 的定义与**口径陷阱**；交叉验证、时序交叉验证、数据泄漏
6	**稳健统计**	中位数 vs 均值、分位数、截断/修剪、重尾分布。你的 `Q_TRUE_MAX=60` 就是一次"截断"

第 3 层 • 写论文用

#	方向	为什么需要
7	**响应面法 / 试验设计术语**	编码变量、设计空间、可旋转性、失拟检验、典型分析、脊线分析。这些词能把你的方法"翻译"成审稿人熟悉的语言
8	**领域物理**	差压式流量计的 $Q \propto \sqrt{\Delta p/\rho}$（伯努利方程）。这是你把 √Δp 当自变量的全部理由

第 4 层 • 进阶（不急）

- 数值线性代数：为什么实践中不显式求逆，而用 QR / Cholesky / SVD
- 代理模型（surrogate model）：克里金 / 高斯过程 / 拉丁超立方抽样，以及它们和多项式响应面的取舍

推荐资源（中文优先）

方向	资源
线性模型矩阵形式	陈希孺《线性模型引论》；Hastie《统计学习基础》(ESL) 第 3 章，免费：https://hastie.su.domains/ElemStatLearn/
岭回归 / 正则化	ESL 第 3.4.1 节；Hoerl & Kennard (1970) *Technometrics* 12(1):55–67

方向	资源
交叉验证 / 重采样	《统计学习导论》(ISLR) 第 5 章，免费：https://www.statlearning.com/
RSM 术语体系	见 `RSM入门论文推荐.md`（中文文献清单）

第 2 章 · 核心公式完整推导

记号约定

符号	含义	代码里叫
$\xi = (\xi_1, \xi_2, \xi_3, \xi_4)^\top$	原始自变量 = $(\sqrt{\Delta p},\ P,\ T,\ Q_{in})^\top$	`df[FEATURES]`
y	目标真值 = 首信体积流量	`q_true`
n	训练样本数（≈ 647,893）	`len(train)`
p	基函数个数 = 14	`Z.shape[1]`

2.0 数据清洗（`rsm_data.py`）

保留样本集合：

$$ \mathcal{S}=\Big\{u:\ \Delta p_u>0,\ P_u>0,\ T_u\ \text{有效},\ Q_{in,u}>1,\ \textstyle\sum_k \text{pump}_{k,u}>0,\ 0

这一步的**为什么**（数学上的理由，不是工程习惯）：

y 的分布是重尾的——中位数 16.97，最大值 3774。残差平方和

$$SS_{res} = \sum_u (\hat{y}_u - y_u)^2$$

里，单个 $y = 3774$ 的样本贡献 $\sim 1.4 \times 10^7$。0.17% 的样本吞掉 99% 的平方误差，线性回归的系数会被这几十个点完全劫持。**这叫"少数点支配目标函数"，是 OLS 无稳健性的直接体现**（因为 OLS 对残差是平方惩罚，惩罚随误差超线性增长）。

2.1 派生变量：√Δp 从哪来（`rsm_data.py` L60）

差压式流量计的物理内核（伯努利方程 + 文丘里/孔板）：

$$Q = C_d \varepsilon A \sqrt{\frac{2\Delta p}{\rho}} \quad \Longrightarrow \quad Q \propto \sqrt{\frac{\Delta p}{\rho}}$$

所以取 $\xi_1 = \sqrt{\Delta p}$ 是**物理线性化**：把"流量 ~ 压差的平方根"这个非线性关系，在进入模型之前先掰直，让低阶多项式就够用。

> ⚠️ 注意埋在这里的一个隐患：$\sqrt{\Delta p/\rho}$ 里的 ρ（混合密度）**没有被测量**，它被吸收进了系数。这是你 R^2 天花板卡在 0.57 的数学原因——模型里有一个真实存在但不可见的自变量。

2.2 中心化（`rsm_model.py` L48-49）

$$\mu = \frac{1}{n}\sum_{u=1}^{n} \xi_u \qquad \text{(只用训练集算，这一步是铁律)}$$

$$x_u = \xi_u - \mu$$

为什么必须做（三条，越往下越重要）：

1. **消除一次项与平方项在样本上的相关。** 中心化后 $\sum_u x_{uj} = 0$，于是 $\sum_u x_{uj} \cdot x_{uj}^2 = \sum_u x_{uj}^3 \approx 0$（$x$ 近似对称）。
   不中心化时 $\sum_u \xi_{uj}\xi_{uj}^2 = \sum_u \xi_{uj}^3$ **很大**，导致一次项和平方项系数必须一正一负互相抵消——你实测到的 `P: +31.97 / P²: -34.28` 就是这个病。
2. **降低条件数 $\kappa(Z^\top Z)$。** 条件数越小，解越稳，系数对数据扰动越不敏感。
3. **让系数可解释。** 中心化后 β_j 的物理含义变成"**在典型工况附近**，ξ_j 变动 1 个单位对 y 的边际影响"。

2.3 二次展开：4 → 14（`rsm_model.py` L52-53）

$$f(x) = \left[\, x_1,\ x_2,\ x_3,\ x_4,\ x_1^2,\ x_2^2,\ x_3^2,\ x_4^2,\ x_1x_2,\ x_1x_3,\ x_1x_4,\ x_2x_3,\ x_2x_4,\ x_3x_4 \,\right]^\top \in \mathbb{R}^{14}$$

项数公式（经典 RSM 的标准结果）：

$$\#\text{基函数} = \underbrace{k}_{\text{一次项}} + \underbrace{k}_{\text{平方项}} + \underbrace{\frac{k(k-1)}{2}}_{\text{交叉项}} = 4 + 4 + 6 = 14, \qquad k = 4$$

模型假设：

$$\mathbb{E}[\,y \mid \xi\,] = \beta_0 + \sum_{j=1}^{14} \beta_j\, f_j(\xi - \mu) = \beta_0 + f(x)^\top \beta$$

同一个模型的另一种写法（二次型，写论文和讲几何时用）：

$$\mathbb{E}[y \mid \xi] \;=\; \gamma_0 + \mathbf{g}^{\top} d + \tfrac{1}{2}\, d^{\top} \mathbf{B}\, d, \qquad d = \xi - \mu$$

其中 $\mathbf{g} \in \mathbb{R}^4$ 是一次项系数，$\mathbf{B}$ 是 4×4 **对称矩阵**，满足
$\mathbf{B}_{jj} = 2\beta_{(\text{平方项}j)}$，$\mathbf{B}_{ij} = \beta_{(\text{交叉项}ij)}$。

> 这个 $\mathbf{B}$ 就是你后面做"典型分析"判别极大/极小/鞍点时要看特征值的那个矩阵。
>
> ⚠ **写论文的坑**：README 里把平方项写成 "$\Delta p,\ P^2,\ T^2,\ Q_{in}^2$"，但严格讲基函数是 $x_1^2 = (\sqrt{\Delta p} - \mu_1)^2 = \Delta p - 2\mu_1\sqrt{\Delta p} + \mu_1^2$，**不是 Δp**。所以公式里的项必须带 `*` 号（表示中心化后的变量），别直接当成原始变量写进论文。

2.4 标准化（`rsm_model.py` L57-58）

对 14 个基函数逐列：

$$m_j = \frac{1}{n}\sum_u Z_{uj}, \qquad s_j = \sqrt{\frac{1}{n}\sum_u \left(Z_{uj} - m_j\right)^2}, \qquad Z^s_{uj} = \frac{Z_{uj} - m_j}{s_j}$$

结果：Z^s 每列均值 0、标准差 1（sklearn 用总体标准差，ddof=0）。于是

$$\frac{1}{n}\,(Z^s)^{\top} Z^s \;=\; R \qquad (R \text{ 是相关系数矩阵，对角元素全为 } 1)$$

为什么必须做：岭回归的惩罚项 $\alpha\|\beta\|^2$ 对**所有系数一视同仁**。如果各列量纲差 100 倍（√Δp 约 5、T 约 46），惩罚就会系统性偏袒量纲大的列 → 引入无意义的偏差。标准化后惩罚才是"公平"的。

2.5 岭回归求解（`rsm_model.py` L61-62）★ 核心

目标函数：

$$L(\beta) \;=\; \left\| y - Z^s\beta \right\|_2^2 \;+\; \alpha\,\|\beta\|_2^2$$

对 β 求梯度并令其为 0：

$$\frac{\partial L}{\partial \beta} = -2\,(Z^s)^{\top}\left(y - Z^s\beta\right) + 2\alpha\beta = 0$$

$$\boxed{\hat{\beta}_{\text{ridge}} \;=\; \left((Z^s)^{\top} Z^s + \alpha I\right)^{-1} (Z^s)^{\top} y}$$

这就是 `ridge.fit(Zs, y)` 内部算的东西——一行闭式解，不是迭代。

截距：因为 Z^s 各列均值已经是 0，sklearn 内部中心化后得到

$$b = \bar{y} = \frac{1}{n}\sum_u y_u$$

与 OLS 的唯一差别就是那个 αI：

$$\hat{\beta}_{\text{OLS}} = \left((Z^s)^\top Z^s\right)^{-1}(Z^s)^\top y \qquad \longleftrightarrow \qquad \hat{\beta}_{\text{ridge}} = \left((Z^s)^\top Z^s + \alpha I\right)^{-1}(Z^s)^\top y$$

- $\alpha \to 0$：退化为 OLS
- $\alpha \to \infty$：$\hat{\beta} \to 0$，预测趋于常数 $\bar{y}$
- α 的作用是**给矩阵对角线上加一个正数**，保证 $Z^{s\top}Z^s + \alpha I$ 可逆且条件数下降

2.6 系数还原（`rsm_model.py` L80-108）

模型是在 Z^s 空间上学的，这套系数不能直接用。做一次逆变换：

$$\hat{y} = \sum_{j=1}^{14} w_j\, Z_j^s + b = \sum_j w_j \cdot \frac{Z_j - m_j}{s_j} + b = \sum_j \underbrace{\frac{w_j}{s_j}}_{c_j} Z_j + \underbrace{\left(b - \sum_j \frac{w_j m_j}{s_j}\right)}_{c_0}$$

对应代码就两行：

```
coef_on_Z = w / scale                                  # c_j = w_j / s_j
intercept = b - float(np.sum(w * mean / scale))        # c_0 = b - Σ w_j m_j / s_j
```

2.7 最终显式公式（`outputs/RSM显式公式.txt`）

$$\boxed{\hat{Q}(\xi) \;=\; c_0 + \sum_{j=1}^{14} c_j\, f_j(\xi - \mu)}$$

一个重要性质：当 $\xi = \mu$（所有变量取训练集均值）时，$x = 0$，于是 $f(x) = 0$，公式退化为

$$\hat{Q}(\mu) = c_0$$

所以常数项 c_0 的物理意义就是"典型工况下的预测流量" —— 你的输出里 $c_0 = 15.991933$ L/s，而首信流量中位数是 16.97，完全合理。

2.8 指标（`rsm_metrics.py`）

相对误差：

$$r_u = \frac{|\hat{y}_u - y_u|}{y_u}$$

$$\text{中位误差} = \text{median}\{r_u\}, \qquad \text{p90} = \text{quantile}_{0.9}\{r_u\}$$

决定系数：

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_u (\hat{y}_u - y_u)^2}{\sum_u (y_u - \bar{y})^2} = 1 - \left(\frac{RMSE}{\sigma_y}\right)^2$$

看清最后那个等号：R^2 的分母是**该数据集自己的标准差 σ_y**。

> 这就是你 `精读指南.md` Q4 里那个"验证集误差更小、R² 反而最低"之谜的完整答案——**分母不同，R² 就不可比**。数学上只要把分母换成统一的 $\sigma_y^{(\text{train})}$，问题就消失：

$$R^2_{\text{统一分母}} = 1 - \left(\frac{RMSE}{\sigma_y^{(\text{train})}}\right)^2$$

代入你的数字（现值已验证）：

数据集	σ_y（自己的分母）	RMSE	原 R²	统一分母 R²
训练集	3.4641	1.9465	0.6843	**0.6843**
验证集	2.1218	1.7853	0.2921	**0.7344**
测试集	3.9200	2.5849	0.5652	**0.4432**

统一分母后出现了**原本被掩盖的事实：测试集才是最差的（0.4432）**。这符合预期——测试集是"未来的数据"。原来的 0.5652 之所以看着还行，纯粹是因为它自己的 σ_y 大。

这是可以直接写进论文的一个发现。

2.9 时序切分与外推（`rsm_data.py` L65-76）

为什么不能随机切：流量是连续变量，自相关

$$\rho(\Delta t) = \text{corr}\big(\xi(t), \xi(t+\Delta t)\big)$$

衰减很慢。随机切分时，测试点 u 的**时间邻居**几乎必然落在训练集里，于是训练集"见过"和测试点几乎一样的输入 → 泛化误差估计被严重低估。**数学上这叫破坏了 i.i.d. 假设**，训练集与测试集不再独立。

外推为什么会爆炸：沿单一变量方向 $d = t\,\mathbf{e}_j$，二次型退化为抛物线：

$$\hat{Q} = c_0 + g_j t + \tfrac{1}{2} B_{jj} t^2$$

t 一大，$\frac{1}{2}B_{jj}t^2$ 就绝对主导。你的 $B_{PP} = 2 \times (-34.29) = -68.58 < 0$，抛物线下开口 → P 往训练范围外走，流量急剧下降、穿过 0 变成负数。

第 3 章 • 代码 ↔ 公式 逐行对照

`rsm_model.py :: fit_model`

代码	公式	干什么
`center = X.mean(axis=0)`	$\mu = \frac{1}{n}\sum_u \xi_u$	求训练集均值
`Xc = X - center`	$x = \xi - \mu$	中心化
`poly.fit_transform(Xc)`	$Z = f(x) \in \mathbb{R}^{14}$	二次展开
`scaler.fit_transform(Z)`	$Z^s = (Z - m) \oslash s$	标准化
`ridge.fit(Zs, y)`	$\hat{\beta} = ((Z^s)^\top Z^s + \alpha I)^{-1}(Z^s)^\top y$	岭回归闭式解
`return {...}`	五个对象：$\mu,\ f,\ m, s,\ \hat{\beta}$, 截距	打包成一个 dict

`rsm_model.py :: predict`

代码	公式
`X = df[features].values - center`	$x = \xi - \mu$
`Z = poly.transform(X)`	$Z = f(x)$
`Zs = scaler.transform(Z)`	$Z^s = (Z - m)/s$
`ridge.predict(Zs)`	$\hat{y} = Z^s\hat{\beta} + b$

> **关键**：变换顺序、参数（μ, m, s）必须和训练时**逐字一致**，且只能用 `transform` 不能用 `fit_transform` ——否则等于在新数据上重新定义了坐标系。

`rsm_model.py :: raw_formula`

代码	公式
`coef_on_Z = w / scale`	$c_j = w_j / s_j$
`intercept = b - np.sum(w*mean/scale)`	$c_0 = b - \sum_j w_j m_j / s_j$

`rsm_metrics.py :: evaluate`

代码	公式
`rel = np.abs(y_pred-y_true)/y_true`	$r_u = \lvert\hat{y}_u - y_u\rvert / y_u$

代码	公式
`np.median(rel)`	$\text{median}\{r_u\}$
`np.percentile(rel,90)`	$\text{quantile}_{0.9}\{r_u\}$
`1 - ss_res/ss_tot`	$R^2 = 1 - SS_{res}/SS_{tot}$

`rsm_data.py :: split_by_time`

代码	公式
`i1 = int(n*0.70)`	$i_1 = \lfloor 0.70\, n \rfloor$
`df.iloc[:i1]`	$\{u:\ u \le i_1\}$（按时间排序后）

第 4 章 · 四个可以自己动手验证的结论

全部已用你 `README.md` / `精读指南.md` 里的数字核算过。

① 常数项 = 典型工况预测值

$\xi = \mu \Rightarrow f = 0 \Rightarrow \hat{Q} = c_0 = 15.99$ L/s。
验证方法：把 14 项全部设成 0，公式只剩常数项。

② P 外推爆炸（对上你 `回复草稿` 里的表）

只留常数项 + P 的一次项和平方项，取 $\mu_P = 0.226$、$c_P = 6.727382$、$c_{P^2} = -34.29$：

$$\hat{Q} \approx 15.991933 + 6.727382\,(P - 0.226) - 34.29\,(P - 0.226)^2$$

P (MPa)	手算值 (L/s)	你草稿里的值 (L/s)
0.226	15.99	16.72
0.50	15.26	15.63
1.00	**0.66**	**0.37**
1.50	**−31.09**	**−32**

量级完全对上——**你已经用一条抛物线解释了全部外推现象。**

③ 你的岭回归等于没做

设最短处理：$Z^{s\top}Z^{s}$ 的第 j 个特征值为 λ_j。由于每列标准化后 $\sum_u (Z^s_{uj})^2 = n$，所以

$$\mathrm{tr}\big((Z^s)^\top Z^s\big) = \sum_j \lambda_j = 14n \approx 14 \times 647{,}893 \approx 9.07 \times 10^6$$

即 λ_j 的量级是 $n \approx 6.5 \times 10^5$。岭回归在主成分方向上的**收缩因子**是

$$\frac{\lambda_j}{\lambda_j + \alpha}$$

α	收缩因子	说明
0.01	1.0000000	完全不缩
1.0	**0.9999985**	← 你的当前设置，等于没缩
100	0.99985	还是没缩
10^4	0.9848	开始有感觉
10^6	0.393	明显收缩

结论：$\alpha = 1$ 相对 $\lambda \sim 6.5 \times 10^5$ 小了 6 个数量级，所以你的估计量在数值上 ≈ OLS。
这解释了你 精读指南 实验 5 的现象，也意味着：**想让岭回归真正起作用，α 得取到 $10^4 \sim 10^6$ 量级**，而不是 $0.01 \sim 10$。

④ 统一分母的 R²

$$1 - \left(\frac{1.7853}{3.4641}\right)^2 = 0.7344$$

正好等于你 精读指南 Q4 里说的 0.7344。验算通过。

第 5 章 · 公式速查卡

```
┌─ 输入 ──────────────────────────────────────────┐
│  ξ = (√Δp, P, T, Q_in)          4 个原始变量          │
├─ 变换 ──────────────────────────────────────────┤
│  x  = ξ − μ                     μ = 训练集均值        │
│  Z  = f(x) ∈ R^14               4 一次 + 4 平方 + 6 交叉│
│  Zs = (Z − m) / s               逐列均值 0、标准差 1   │
├─ 求解 ──────────────────────────────────────────┤
│  β̂ = ((Zs)ᵀZs + αI)⁻¹ (Zs)ᵀ y   ★ 岭回归闭式解        │
│  b = ȳ                                          │
├─ 还原 ──────────────────────────────────────────┤
```

```
│  $c_j = w_j / s_j$                                          │
│  $c_0 = b - \Sigma_j w_j m_j / s_j$                         │
├─ 显式公式 ──────────────────────────────────────────────────┤
│  $\hat{Q}(\xi) = c_0 + \Sigma_j c_j f_j(\xi - \mu)$         │
│  性质：$\xi = \mu$ 时 $\hat{Q} = c_0$ (≈ 15.99 L/s)        │
├─ 评价 ──────────────────────────────────────────────────────┤
│  $r = |\hat{y} - y| / y$   → 中位数 / p90                   │
│  $R^2 = 1 - (RMSE/\sigma_y)^2$   ⚠ 分母随数据集变，不可直接比 │
├─ 外推 ──────────────────────────────────────────────────────┤
│  沿单变量方向：$\hat{Q} \approx c_0 + g_j t + \frac{1}{2} B_{jj} t^2$   → t 大时爆炸 │
└──────────────────────────────────────────────────────────────┘
```

附：如果你在 VS Code 里看不到公式渲染

`精读指南.md` 和你这份文档都用了 LaTeX 公式。VS Code 内置预览默认不渲染数学公式，装一个扩展即可：

- **Markdown+Math** 或 **Markdown Preview Enhanced**

装完用 `Ctrl+Shift+V` 打开预览就能看到正常排版的公式。

如果不想装扩展，跟我说一声，我可以出一版 **HTML（内置公式渲染）**，双击用浏览器打开即可。